

LLM ENGINEER · ФИНАЛЬНЫЙ ПРОЕКТ · 2026

MedAgent

Ассистент по анализам для пациентки с ПБХ и циррозом
печени

Фото/PDF анализа → подтверждение человеком → уровень тяжести → объяснение на казахском
и русском

Kassiyet Topysheva · github.com/kassiyet-13/MedAgent

Анализом много, понимания нет

1–3 мес

анализы: биохимия, ОАК,
коагулограмма, ОАМ

30–40

показателей в одном анализе,
у каждой лаборатории
свои нормы

2 языка

бланки на русском и
казахском, фото и PDF

Семья не находит ответа на три вопроса: **что изменилось? насколько это серьёзно? когда идти к врачу?**

Что делает MedAgent



Читает

Фото и многостраничные PDF, бланки RU/KZ. Claude Sonnet 5 vision, GPT-4o — резерв



Спрашивает

Таблица: вне нормы / норма, можно исправить. Без подтверждения ничего не сохраняется



Оценивает

Уровень тяжести — правилами, не LLM. Критический порог → «к врачу сейчас»




Объясняет

Простым языком, сначала по-казахски, затем по-русски. С опорой на руководства

Дополнительно: несколько анализов сразу · история и тренды, MELD-Na · чат по своим документам · еженедельная самооценка

От загрузки до объяснения



Несколько анализов сразу

Параллельное чтение (3 потока) → очередь по дате → подтверждение по одному → «Следующий анализ →». Один анализ в двух файлах распознаётся по содержанию

После сохранения

Тренд каждого показателя, MELD-Na, чат с вопросами вроде «когда был последний фиброскан?»

Три слоя

Интерфейс

Streamlit, 5 страниц, меню на казахском. Анализы, документы, история, чат, самооценка



Оркестрация

LangGraph: 20 узлов, 2 HITL, циклы. SqliteSaver — состояние переживает перезагрузку страницы



Инструменты и знания

Свой MCP-сервер (3 tool) · Chroma ×2 + rerank · Skill · SQLite

Модели

Claude Sonnet 5 — OCR и объяснение · GPT-4o — резервный OCR · Claude Haiku 4.5 — rerank · text-embedding-3-small · LangSmith — трейс каждого узла и вызова

Ветвления, циклы, решение человека

Ветвления

Тип документа: анализ или текст (выписка, УЗИ). 3 тона по уровню тяжести: предупреждение · совет · поддержка

Циклы

Повтор подтверждения (≤ 3 , затем «загрузите фото чётче»).
При низкой релевантности RAG ищет снова (≤ 2)

HITL: interrupt()

Подтверждение значений — **всегда**: модель ошиблась при самооценке 0.95. Подтверждение сохранения — после просмотра результата

Оценка правилами

Критический порог → «к врачу сейчас» · вне нормы → «в ближайшее время» · иначе «наблюдение»

RAG • MCP • Skill



RAG, 2 коллекции

Руководства: 14 документов,
AASLD/EASL, протокол МЗ РК по ПБХ

Своя история: выписка,
УЗИ, FibroScan

Naiku reranker: нужный фрагмент был
13-м из 33 по эмбедингам



Свой MCP-сервер

get_reference_ranges
compute_trend (+ MELD-Na)
search_knowledge

Типизированные схемы, отдельные
тесты, отдельный шаг в трейсе



Skill

pbc-cirrhosis-explainer: инструкция,
гlossарий KZ/RU, шаблоны тона

Загружается только в узле
объяснения (progressive disclosure)

Опасные решения принимает не LLM

Что	Как и почему
Уровень тяжести	Правила, не LLM — тестируется (12/12)
Подтверждение значений	Всегда — самооценке модели верить нельзя
Prompt injection	Паттерны RU/KZ/EN, проверка независима от модели
Персональные данные	Очистка до эмбединга: regex KZ/RU + Presidio
«Это не диагноз»	Проверяет код, на обоих языках
Граница	Снимки УЗИ/КТ не интерпретируются, только заключение врача

EVALS

30 примеров, 6 метрик, одна команда

97.8%

точность чтения
значений (139
значений, 10
реальных бланков)

12/12

уровень тяжести, 0
пропущенных critical

5.00

faithfulness, судья
GPT-4o (22
объяснения)

3/3

prompt injection
обнаружено

4.4

правильность чата по
истории (5), одна
реальная ошибка

Golden dataset: **10** реальных анализов · **12** синтетических пограничных случаев · **3** атаки · **5** вопросов в чат. Accuracy + LLM-as-judge. `python -m evals.run_evals`

Eval – инструмент поиска ошибок

Найдено	Исправлено
Казахский prompt injection проходил (66.7%)	Новые паттерны KZ/RU → 100%
Дата рождения и фамилия в векторной базе	3 правила PII, база очищена заново
При critical список «обязательно упомянуть» пуст	Исправлен классификатор
Судья gpt-4o-mini поставил 5/5 неверному ответу	GPT-4o + строгая рубрика
Один анализ в двух PDF — сохранён дважды	Дедупликация по содержанию

He temperature, a effort

Claude Sonnet 5 не принимает temperature (400) и по умолчанию «думает». Его рычаг — effort. 6 реальных анализов, всё остальное одинаково.

effort	время	цена	faith.	полный
low	33.9 с	\$0.027	5.00	100%
medium ✓	37.5 с	\$0.030	4.83	100%
high (было)	70.9 с	\$0.058	4.67	83%

71 → 37 с

ожидание после «Растаймын»

high вдвое медленнее и дороже, качество не лучше, однажды обрезал текст. low ≈ medium; medium выбран как небольшой запас для медицинского текста.

Claude Sonnet 5 vs GPT-4o

22 примера, входы одинаковы	Claude	GPT-4o
Faithfulness	5.00	4.64
Упоминание отклонений	97.3%	93.4%
С неверными утверждениями	0 / 22	8 / 22
Время	34.0 с	4.9 с
Цена	\$0.026	\$0.013

Решение

Claude — основной, GPT-4o — резерв

GPT-4o: «креатинин понижен → функция почек снижена» — медицинская ошибка

Судья — GPT-4o, то есть предвзятость в пользу GPT, но он всё равно проиграл. Цену скорости компенсируют effort и будущий streaming.

Научило реальное использование

Ошибки, найденные на реальных документах

- Ферритин 748 (норма 12–135) получил «стабильно»
- Вторая страница многостраничного PDF терялась
- Значения вроде «отр», «1:80» терялись
- Бралась дата с шапки бланка вместо даты регистрации

Дальше

- Streaming — текст появляется сразу
- Соседние фрагменты в чате (parent-document)
- Оценка казахского текста носителем языка
- Роль врача, PWA для телефона

Спасибо!

Готова ответить на вопросы

github.com/kassiyet-13/MedAgent

[README.md](#) · [ARCHITECTURE.md](#) · [EVALS.md](#)

MedAgent не ставит диагноз и не заменяет врача